

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ

федеральное государственное автономное образовательное учреждение высшего
образования

«САНКТ-ПЕТЕРБУРГСКИЙ ГОСУДАРСТВЕННЫЙ УНИВЕРСИТЕТ
АЭРОКОСМИЧЕСКОГО ПРИБОРОСТРОЕНИЯ»

КАФЕДРА №5

ОЦЕНКА ПРАКТИЧЕСКОЙ РАБОТЫ
ПРЕПОДАВАТЕЛЬ

Профессор, д.т.н., доц.

Н. А. Жильникова

*должность, уч. степень,
звание*

подпись, дата

инициалы, фамилия

«Разработка первой (теоретической) главы ВКР»

по дисциплине: Междисциплинарный проект

РАБОТУ ВЫПОЛНИЛ(А)
СТУДЕНТ(КА) ГР. № М558М

Рослов Д.С.

подпись, дата

инициалы, фамилия

Санкт-Петербург 2026

ГЛАВА 1. ТЕОРЕТИКО-МЕТОДОЛОГИЧЕСКИЕ ОСНОВЫ ИССЛЕДОВАНИЯ РИСКОВ ВНЕДРЕНИЯ ТЕХНОЛОГИЙ ИСКУССТВЕННОГО ИНТЕЛЛЕКТА В ИТ-СЕКТОРЕ

1.1 Современное состояние и тенденции развития технологий искусственного интеллекта в ИТ-секторе

Искусственный интеллект (ИИ) представляет собой совокупность технологий, методов и систем, имитирующих когнитивные функции человека — обучение, рассуждение, восприятие, принятие решений и взаимодействие на естественном языке. Согласно стандарту ISO/IEC 22989:2022, ИИ определяется как «область исследований и технических разработок, охватывающая системы, которые реализуют функции, типично ассоциируемые с интеллектом человека». В Национальной стратегии развития искусственного интеллекта в Российской Федерации до 2030 года (утв. Указом Президента РФ от 10 октября 2019 г. № 490) ИИ трактуется как комплекс технологических решений, позволяющих имитировать когнитивные функции человека и получать при выполнении конкретных задач результаты, сопоставимые как минимум с результатами интеллектуальной деятельности человека.

Внутреннюю архитектуру современных ИИ-систем составляют методы машинного обучения (МО), глубокого обучения (Deep Learning, DL), обработки естественного языка (Natural Language Processing, NLP) и компьютерного зрения. Базовое разграничение указанных понятий приведено в стандарте ISO/IEC TR 24028:2020: МО — подмножество ИИ, основанное на статистическом обучении на данных; DL — подмножество МО, использующее глубокие нейронные сети с большим числом скрытых слоёв; генеративный ИИ (Generative AI) — отдельный класс DL-моделей, способных создавать новый контент (текст, изображения, программный код, аудио). Появление в 2017 г. архитектуры Transformer (A. Vaswani et al., «Attention Is All You Need») заложило основу для нового поколения моделей

— больших языковых моделей (Large Language Models, LLM) и фундаментальных моделей (foundation models), на которых строятся современные коммерческие продукты ChatGPT, GPT-4, Claude, Gemini, YandexGPT, GigaChat.

Развитие ИИ-технологий в IT-секторе происходит в условиях беспрецедентного роста рынка. По данным отчёта Stanford AI Index Report 2024, глобальные инвестиции в ИИ-проекты в 2023 г. достигли 189,2 млрд долл. США, а число публикаций по ИИ в рецензируемых изданиях за период 2010–2023 гг. выросло в 4,7 раза. По оценкам McKinsey Global Institute (2024), технологии генеративного ИИ способны добавить мировой экономике до 4,4 трлн долл. США ежегодного экономического эффекта при условии масштабного внедрения. В Российской Федерации, согласно данным Минцифры и АНО «Цифровая экономика», объём рынка ИИ-технологий в 2023 г. составил 650 млрд руб. с прогнозом роста до 1,7 трлн руб. к 2026 г.; доля компаний, заявивших о применении ИИ в своих процессах, превысила 47 %.

Структура применения ИИ в IT-секторе включает несколько ключевых направлений. Первое — автоматизация разработки программного обеспечения (AI-assisted software engineering): генеративные модели (GitHub Copilot, Amazon CodeWhisperer, Cursor) обеспечивают автодополнение кода, рефакторинг, генерацию модульных тестов. Согласно эмпирическому исследованию GitHub (N. Peng et al., 2023), применение Copilot повышает скорость выполнения типовых задач разработки в среднем на 55,8 %. Второе направление — ИИ-операции и MLOps: автоматизация развёртывания, мониторинга и обновления моделей, управления данными и инфраструктурой. Третье — ИИ в кибербезопасности: системы детекции аномалий, поведенческой аналитики, защита от фишинга и вредоносного программного обеспечения. Четвёртое — ИИ-аналитика и поддержка принятия решений: предиктивная аналитика, ETL, автоматизация бизнес-

отчётности. Пятое — клиентский сервис: интеллектуальные ассистенты, автоматизированная обработка обращений на естественном языке.

Тенденции развития ИИ в IT-секторе в период 2023–2025 гг. характеризуются переходом от экспериментальных пилотов к промышленной эксплуатации (production-grade), увеличением размера моделей при одновременном развитии методов их оптимизации (LoRA, квантование, дистилляция знаний), широким внедрением мультимодальных моделей (text-image-audio), активным развитием парадигмы агентного ИИ (autonomous AI agents) и появлением открытых моделей (Llama, Mistral, Qwen, DeepSeek) как альтернативы закрытым коммерческим решениям. Параллельно наблюдается возрастающий разрыв между темпами появления новых моделей и зрелостью методологии управления связанными с ними рисками.

Российский ИИ-ландшафт формируется крупными технологическими корпорациями, ставшими ядром национальной экосистемы. Компания «Яндекс» в 2023–2024 гг. вывела на рынок модель YandexGPT 3 и семейство мультимодальных моделей; ПАО «Сбербанк» развивает линейку GigaChat и платформу GigaCloud; ПАО «МТС» через дочернюю компанию MTS AI представило коллекцию открытых моделей Cotype и Saiga; Группа «Т1» и «Тинькофф» (Т-Банк) развивают собственные ассистенты в финансовой и технологической сферах. По данным Russia AI Index 2024, в 2023 г. объём патентов в области ИИ, поданных российскими заявителями в Роспатент, превысил 1 800, при этом более половины из них относятся к прикладным IT-задачам — обработке естественного языка, компьютерному зрению и системам поддержки принятия решений.

Эволюция архитектур ИИ-моделей за последние пятнадцать лет включает несколько технологических волн. Первая волна (2012–2017 гг.) — глубокие свёрточные сети (CNN: AlexNet, VGG, ResNet) и рекуррентные сети (RNN, LSTM, GRU). Вторая волна (2017–2021 гг.) — архитектура Transformer и предобученные языковые модели (BERT, GPT-2, GPT-3).

Третья волна (2022–2025 гг.) — крупномасштабные генеративные и мультимодальные модели (GPT-4, Claude 3.5, Gemini Ultra, Llama 3, GigaChat 2.0). Каждая волна сопровождалась многократным ростом числа параметров: от десятков миллионов в CNN до сотен миллиардов в современных LLM. Параллельно развиваются методы повышения эффективности — Mixture of Experts (MoE), разреженная активация, кэширование промежуточных представлений, что позволяет частично компенсировать рост вычислительной стоимости моделей.

Таким образом, ИИ-технологии становятся системообразующим компонентом современного IT-сектора и фактором его конкурентной стратификации. Однако высокая скорость их развития и сложность внутреннего устройства порождают качественно новые источники рисков, что обуславливает необходимость их детальной классификации и систематизации.

1.2 Понятие и классификация рисков внедрения ИИ-технологий в IT-компаниях

Понятие риска в контексте внедрения ИИ-технологий интерпретируется в соответствии со стандартом ГОСТ Р ИСО 31000-2019 «Менеджмент риска. Принципы и руководство» как «влияние неопределённости на цели». Применительно к ИИ-проектам в IT-секторе риск понимается как вероятностное событие или состояние, наступление которого приводит к отклонению фактических результатов внедрения от запланированных по срокам, стоимости, функциональности, безопасности или соответствию нормативным требованиям. В соответствии с международным стандартом ISO/IEC 23894:2023 «Artificial intelligence — Guidance on risk management» оценка рисков ИИ должна выполняться на всех этапах жизненного цикла системы — от проектирования и обучения до развёртывания, эксплуатации и вывода из работы.

Анализ литературы и регулирующих документов (NIST AI Risk Management Framework 1.0, 2023; EU Artificial Intelligence Act, 2024; OECD AI Principles, 2019/2024) позволил выделить шесть укрупнённых категорий рисков, специфичных для внедрения технологий ИИ в IT-компаниях: технологические, информационно-безопасностные, организационно-кадровые, финансово-экономические, регуляторно-этические и репутационные. Каждая из категорий включает группу конкретных рисков, имеющих собственные источники, механизмы материализации и индикаторы.

Технологические риски обусловлены свойствами самих ИИ-моделей и процессов их разработки. К ключевым из них относятся: эффект галлюцинаций (генерация моделью правдоподобных, но фактически ложных утверждений), смещение модели (model bias) — систематическая ошибка, возникающая из-за несбалансированности обучающих данных, и дрейф концепции (concept drift) — постепенное ухудшение точности модели вследствие изменения свойств входных данных в эксплуатации. Дополнительными источниками технологических рисков являются нестабильность результатов обучения (low reproducibility), уязвимость моделей к атакам состязательных примеров (adversarial examples) и риск утраты интерпретируемости (black-box problem) при росте сложности сетей.

Реальные инциденты подтверждают практическую значимость рассматриваемых рисков. В 2018 г. компания Amazon была вынуждена отказаться от внутреннего инструмента подбора персонала, основанного на машинном обучении, из-за обнаруженного систематического смещения в пользу мужских кандидатов: модель, обученная на резюме за десять предшествующих лет, унаследовала исторические гендерные перекося. В 2023 г. дело *Mata v. Avianca* (США) показало риск галлюцинаций в юридической практике: адвокат, использовавший ChatGPT для поиска прецедентов, представил суду шесть несуществующих судебных решений, сгенерированных моделью. В 2016 г. чат-бот Tay компании Microsoft был

отключён через 16 часов после запуска вследствие манипуляций пользователей, приведших к генерации оскорбительного контента. Указанные инциденты иллюстрируют качественную природу ИИ-рисков: вероятность их материализации сложно оценить статистически, однако последствия в части репутации и юридических обязательств являются масштабными.

Риски информационной безопасности тесно связаны с технологическими, но имеют самостоятельную природу. К ним относятся: атаки извлечения обучающих данных (membership inference, model inversion), атаки отравления данных (data poisoning), утечка персональных данных через выходы модели, взлом инфраструктуры обучения и развёртывания, целенаправленные prompt-инъекции в LLM-приложениях. По данным отчёта IBM Cost of a Data Breach 2024, инциденты с участием ИИ-систем характеризуются средним ущербом 4,88 млн долл. США, что на 11 % превышает среднеотраслевой показатель.

Организационно-кадровые риски возникают на этапе встраивания ИИ-технологий в производственные процессы IT-компаний. К числу наиболее значимых относятся: кадровый дефицит специалистов (дата-инженеров, ML-инженеров, MLOps-инженеров), сопротивление сотрудников внедрению автоматизации, разрыв компетенций между командами разработки и эксплуатации, отсутствие формализованного процесса MLOps, фрагментация и низкое качество корпоративных данных. Согласно данным Russia AI Index 2024, дефицит ИИ-специалистов в РФ к 2026 г. оценивается в 70–80 тыс. чел.

Финансово-экономические риски связаны с высокой стоимостью ИИ-инициатив и неопределённостью возврата инвестиций. К ним относятся: превышение бюджета на инфраструктуру (вычислительные мощности, GPU), затраты на лицензирование коммерческих моделей, стоимость аннотирования обучающих выборок, риск недо-достижения целевых бизнес-показателей. Эмпирические исследования Gartner (2024) и IDC (2024)

показывают, что от 70 до 85 % проектов внедрения ИИ не достигают заявленных бизнес-целей по срокам, бюджету или качеству продукта.

Регуляторно-этические риски связаны с необходимостью соблюдения требований законодательства и общественных норм. К ним относятся: несоответствие ИИ-системы требованиям защиты персональных данных (152-ФЗ, GDPR), нарушение недискриминационных принципов, использование объектов интеллектуальной собственности без разрешения правообладателей, нарушение Кодекса этики в сфере искусственного интеллекта (2021). Принятый в 2024 г. EU AI Act вводит классификацию ИИ-систем по уровню риска (запрещённые, высокого, ограниченного и минимального риска) и устанавливает для каждой категории жёсткие требования к документированию, прозрачности и аудиту.

Систематизация рисков ИИ удобно представляется в форме матрицы риска, в которой каждая категория описывается комбинацией трёх характеристик: значимости последствий (Severity), частоты проявления (Occurrence) и обнаруживаемости (Detection). Указанные характеристики совпадают с показателями FMEA-анализа, что обеспечивает методическую совместимость разрабатываемой типологии с инженерными методами оценки рисков. Исследование S. Yazdi и соавторов (2020 г.) показало, что для ИИ-проектов значения отдельных компонент RPN коррелируют слабо: значимость последствий определяется бизнес-контекстом, частота проявления — качеством обучающих данных, обнаруживаемость — наличием средств мониторинга и тестирования. Это обуславливает необходимость применения нелинейных схем агрегирования факторов и подтверждает целесообразность нечёткой логики как инструмента интеграции разнородных оценок.

Репутационные риски замыкают классификацию и проявляются как негативная реакция пользователей, СМИ и партнёров на инциденты с участием ИИ-систем (некорректные ответы, утечки, дискриминация, несоответствие этическим нормам). Реализация репутационных рисков, как

правило, является интегральным следствием материализации рисков из других категорий.

Резюмируя, представленная классификация формирует многоаспектную модель рисков внедрения ИИ-технологий, охватывающую технологическое, информационно-безопасностное, организационное, финансовое, регуляторное и репутационное измерения. Существенным признаком всех категорий является качественный, плохо формализуемый характер большинства источников и индикаторов, что обуславливает специфические требования к выбору методов их оценки.

1.3 Нормативно-правовая база регулирования искусственного интеллекта и управления рисками

Эффективное управление рисками внедрения технологий искусственного интеллекта возможно только в правовом и методическом поле. Действующая в Российской Федерации и за рубежом нормативная база представлена тремя уровнями документов: стратегические и рамочные акты, технические стандарты и отраслевые регуляторные требования.

На стратегическом уровне в Российской Федерации основополагающим документом является Указ Президента РФ от 10 октября 2019 г. № 490 «О развитии искусственного интеллекта в Российской Федерации», утвердивший Национальную стратегию развития ИИ до 2030 года. В 2024 г. Указом Президента РФ от 15 февраля 2024 г. № 124 в Стратегию внесены изменения, расширяющие задачи обеспечения технологического суверенитета и безопасности ИИ-систем. Кроме того, действует Федеральный закон от 24 апреля 2020 г. № 123-ФЗ «О проведении эксперимента по установлению специального регулирования в целях создания необходимых условий для разработки и внедрения технологий искусственного интеллекта»; Кодекс этики в сфере искусственного интеллекта, подписанный ведущими российскими компаниями 26 октября

2021 г.; Федеральный закон от 27 июля 2006 г. № 152-ФЗ «О персональных данных», регулирующий обработку обучающих выборок.

Базовый набор технических стандартов в области управления рисками включает национальный стандарт ГОСТ Р ИСО 31000-2019 «Менеджмент риска. Принципы и руководство», ГОСТ Р 51901.23-2012 «Менеджмент риска. Реестр риска», ГОСТ Р ИСО/МЭК 31010-2021 «Менеджмент риска. Методы оценки риска», а также комплекс стандартов по доверенному ИИ: ГОСТ Р 59276-2020 «Системы искусственного интеллекта. Способы обеспечения доверия. Общие положения», ГОСТ Р 59277-2020, ГОСТ Р 59895-2021. На международном уровне ключевыми являются стандарты ISO/IEC 23894:2023 «Artificial intelligence — Guidance on risk management», ISO/IEC 42001:2023 «AI management system», ISO/IEC TR 24028:2020 «Trustworthiness of AI», ISO/IEC 22989:2022.

Регуляторно-методическим документом международного значения является Artificial Intelligence Risk Management Framework (NIST AI RMF 1.0), опубликованный Национальным институтом стандартов и технологий США в январе 2023 г. Документ формализует четыре ключевых функции управления рисками ИИ: управлять (Govern), картировать (Map), измерять (Measure), управлять (Manage), и устанавливает универсальные характеристики доверенного ИИ — обоснованность, надёжность, безопасность, защищённость, приватность, объяснимость, справедливость и управляемость. В 2024 г. Европейский союз принял Регламент Artificial Intelligence Act (Regulation (EU) 2024/1689), вступивший в силу 1 августа 2024 г. и устанавливающий обязательные требования к ИИ-системам, классифицированным по уровню риска.

Регламент EU AI Act выделяет четыре уровня риска. Первая категория — запрещённые практики (биометрическая массовая идентификация в реальном времени в общественных местах, социальное скоринговое ранжирование, манипулятивные системы); их применение полностью исключается. Вторая категория — высокорисковые системы (биометрия,

системы управления критической инфраструктурой, системы образования и приёма на работу, кредитного скоринга, правоохранительной деятельности); к ним применяются требования по управлению рисками, качеству данных, документированию, прозрачности, человеческому контролю и кибербезопасности. Третья категория — системы ограниченного риска (чат-боты, генеративный контент); требуется уведомление пользователя о взаимодействии с ИИ. Четвёртая категория — системы минимального риска; жёсткие требования не предъявляются. За нарушение требований Регламент предусматривает штрафы до 35 млн евро или 7 % мирового оборота компании (ст. 99). Аналогичный уровень ответственности с 2024 г. формируется и в США — в виде положений Executive Order 14110 «On the Safe, Secure, and Trustworthy Development and Use of Artificial Intelligence».

Отраслевые требования формируются регуляторами в области информационной безопасности и защиты данных. ФСТЭК России в 2023–2024 гг. выпустила методические рекомендации по обеспечению безопасности ИИ-систем, обрабатывающих информацию ограниченного распространения, включая защиту от состязательных атак и извлечения обучающих данных. Банк России в Указании от 2 июля 2021 г. № 5847-У и в стандарте СТО БР ИББС-1.4-2018 регламентирует управление модельным риском в кредитных организациях, в том числе при использовании моделей машинного обучения. Минцифры России в 2023 г. утвердило перечень особо значимых проектов по разработке и внедрению ИИ, реализуемых при государственной поддержке.

Соблюдение нормативно-правовых требований выступает одним из источников регуляторного риска и одновременно методической основой для построения моделей оценки рисков. Проведённый обзор показывает, что сформирована достаточная нормативная база в области управления рисками вообще и рисками ИИ в частности, однако прикладные методики оценки специфических рисков ИИ представлены преимущественно на уровне

рамочных рекомендаций и требуют отраслевой адаптации применительно к ИТ-сектору.

1.4 Методы оценки рисков и обоснование применимости аппарата нечёткой логики

Методический инструментарий оценки рисков, применяемый в управленческой и инженерной практике, традиционно делится на качественные, количественные и смешанные методы. Качественные методы (мозговой штурм, метод Дельфи, чек-листы, SWOT-анализ, построение карт рисков) позволяют идентифицировать риски и ранжировать их экспертно по уровням вероятности и тяжести последствий. Количественные методы (статистическое моделирование, имитационное моделирование Монте-Карло, дерево событий, дерево отказов, FMEA, FMECA, HAZOP, Bayesian network) позволяют получать численные оценки вероятностей и величин последствий, однако требуют наличия репрезентативных эмпирических данных. Смешанные методы (полуколичественный FMEA, нечёткие методы) сочетают экспертные оценки с количественными агрегатами и оптимальны в условиях неполноты данных, типичной для ИИ-проектов.

Метод FMEA (Failure Mode and Effects Analysis), разработанный в оборонной промышленности США в 1949 г. и стандартизованный в стандартах IEC 60812, AIAG-VDA FMEA Handbook 2019, ГОСТ Р 27.303-2021, занимает в современной практике центральное место благодаря своей универсальности и пригодности к работе в условиях ограниченных эмпирических данных. Классический FMEA предусматривает идентификацию режимов отказа, их последствий и причин, экспертную оценку трёх показателей по 10-балльной шкале — значимости (Severity, S), частоты (Occurrence, O) и обнаруживаемости (Detection, D) — и расчёт коэффициента приоритетности риска $RPN = S \times O \times D$. К ограничениям метода относятся: нелинейность шкал, неравнозначность вкладов

сомножителей, дискретность результата, чувствительность к субъективности экспертных оценок.

Альтернативные подходы — ISO 31000 (риск-менеджмент общего характера), COSO ERM (корпоративный риск-менеджмент), PMI Risk Management Standard (проектные риски) и Bayesian Network — обеспечивают концептуальную и инструментальную поддержку процессов оценки, но при применении к рискам ИИ в IT-секторе обнаруживают системные ограничения. Для технологических рисков ИИ типичными являются малые выборки прецедентов, качественный характер большинства факторов и экспертные оценки в виде нечётких лингвистических термов («низкий», «средний», «высокий», «очень высокий»). Эти особенности существенно ограничивают применение классических методов, требующих чёткой количественной информации.

Решение указанных ограничений видится в применении аппарата нечёткой логики, разработанного Л. А. Заде в 1965 г. (статья «Fuzzy sets» в журнале *Information and Control*, vol. 8, no. 3) и развитого в трудах Е. Мамдани (1975), М. Сугено и Т. Такаги (1985), Дж. Менделя (2001), А. Н. Борисова (1997), А. В. Леоненкова (2003), Н. Г. Ярушкиной (2004) и А. П. Ротштейна (2009). Нечёткая логика оперирует понятием нечёткого множества $A = \{(x, \mu_A(x)) \mid x \in X\}$, где X — универсум рассуждения, $\mu_A : X \rightarrow [0; 1]$ — функция принадлежности. Принципиальное преимущество аппарата состоит в способности формализованно обрабатывать качественные оценки и неполные данные, представляя их в виде лингвистических переменных и нечётких термов с плавными переходами.

Алгоритм нечёткого вывода Мамдани, в наибольшей степени соответствующий задачам оценки рисков, включает четыре этапа: фаззификацию входных переменных (преобразование чётких значений в степени принадлежности нечётким термам), активацию правил (сопоставление текущей ситуации с условиями продукционной базы), агрегирование результатов и дефаззификацию методом центра тяжести,

методом среднего максимума или иным численным методом, дающую итоговую количественную оценку. В нечётком FMEA (fuzzy FMEA), описанном в работах Дж. Боулза и С. Пеляес (1995), А. Гуо и Х. Лю (2013), J. Mendel et al. (2017), значения S, O и D рассматриваются как лингвистические переменные, что позволяет преодолеть ограничения классического FMEA при работе с качественной информацией.

Функции принадлежности $\mu_A(x)$, описывающие нечёткие термы, выбираются из стандартного набора форм: треугольной (trimf), трапецевидной (trapmf), гауссовой (gaussmf), сигмоидальной (sigmf), кусочно-линейной обобщённой колоколообразной (gbellmf). В задачах оценки рисков ИИ преимущество отдаётся треугольным и трапецевидным функциям благодаря их вычислительной простоте, содержательной интерпретируемости и согласованности с экспертными оценками, выдаваемыми в форме интервалов «от — до». Логические операции над нечёткими множествами выполняются с использованием Т-норм (минимум, произведение, ограниченное произведение Лукасевича) и S-норм (максимум, вероятностная сумма, ограниченная сумма). Конкретный выбор операторов влияет на форму итоговой нечёткой поверхности отклика и должен обосновываться при разработке базы правил.

Дефаззификация — заключительный этап нечёткого вывода — представлена несколькими альтернативными методами: центр тяжести (Center of Gravity, CoG), средний максимум (Mean of Maxima, MoM), наименьший максимум (Smallest of Maxima, SoM), наибольший максимум (Largest of Maxima, LoM), биссектриса площади (Bisector). Сравнительный анализ методов, выполненный Дж. Менделем (Mendel, 2017), показывает, что метод центра тяжести обеспечивает наилучший баланс точности, гладкости и вычислительной устойчивости и потому принимается в настоящем исследовании в качестве базового. Дополнительно рассматриваются перспективные направления — нечёткие множества II типа (Type-2 Fuzzy Sets) и интуитивистские нечёткие множества Атанасова, обеспечивающие

учёт неопределённости в самих функциях принадлежности и применимые при недостаточной согласованности экспертных оценок.

Сравнительный анализ методов оценки рисков по совокупности критериев — пригодность к малым выборкам, обработка качественной информации, прозрачность алгоритма, способность учитывать нелинейные взаимосвязи, согласованность с экспертами — обобщён в работах Н. С. Liu (2021) и L. Tian (2023). По их результатам нечёткие гибридные модели (fuzzy FMEA, fuzzy AHP, ANFIS) превосходят классические методы по чувствительности к нелинейностям и по согласованности с лингвистическими экспертными оценками, оставаясь интерпретируемыми и допускающими аудит. Комбинация FMEA с нечётким выводом Мамдани зарекомендовала себя как методический стандарт оценки технологических рисков в условиях неопределённости и ограниченных эмпирических данных, что подтверждает обоснованность её выбора в настоящей работе.

Сопоставление методов оценки рисков по критериям пригодности к ИИ-задачам — работа с малыми выборками, обработка качественных оценок, прозрачность результата, способность учитывать одновременно технологические и организационные факторы — позволяет утверждать, что аппарат нечёткой логики и его интеграция с FMEA обеспечивают наилучший компромисс между методической строгостью и применимостью в реальных условиях. Современные публикации (S. Yazdi et al., 2020; Н. Liu, 2021; L. Tian, 2023) подтверждают, что нечёткие гибридные модели превосходят классический FMEA по чувствительности к нелинейным взаимосвязям факторов и по согласованности с экспертными оценками.

Таким образом, выбор аппарата нечёткой логики в качестве методической основы СППР по оценке рисков внедрения ИИ-технологий в IT-компаниях обоснован спецификой решаемой задачи. Полученные в настоящей главе результаты формируют необходимый теоретический контур для перехода к аналитической и проектной частям диссертационного исследования.

1.5 Выводы по главе 1

По результатам теоретического исследования, выполненного в первой главе, могут быть сформулированы следующие выводы.

1. Технологии искусственного интеллекта, основанные на машинном и глубоком обучении, фундаментальных моделях и генеративных архитектурах семейства Transformer, заняли в 2023–2025 гг. положение системообразующего фактора развития ИТ-сектора. Объём российского рынка ИИ-технологий превысил 650 млрд руб. при прогнозе роста до 1,7 трлн руб. к 2026 г., доля компаний, применяющих ИИ, составила 47 %.

2. Внедрение ИИ-технологий сопряжено со специфическими рисками, качественно отличающимися от рисков классических ИТ-проектов. Предложена авторская типология, объединяющая шесть укрупнённых категорий: технологические, информационно-безопасностные, организационно-кадровые, финансово-экономические, регуляторно-этические и репутационные риски. Существенным общим признаком является качественный и плохо формализуемый характер большинства источников и индикаторов.

3. Сформированная нормативно-правовая база (Указ Президента РФ № 490, ФЗ-123, Кодекс этики ИИ 2021 г., 152-ФЗ, ГОСТ Р ИСО 31000-2019, ГОСТ Р 59276-2020, ISO/IEC 23894:2023, ISO/IEC 42001:2023, NIST AI RMF 1.0, EU AI Act 2024) устанавливает общие методические рамки управления рисками ИИ, однако не содержит конкретных типовых моделей оценки рисков, адаптированных к ИТ-сектору.

4. Анализ существующих методов оценки рисков (качественных, количественных, смешанных) показал, что классические подходы (вероятностный анализ, дерево событий, классический FMEA) имеют ограничения при работе с малыми выборками прецедентов и качественной экспертной информацией, типичными для ИИ-проектов.

5. Аппарат нечёткой логики, базирующийся на работах Л. А. Заде, Е. Мамдани, М. Сугено и развиваемый в трудах А. Н. Борисова, Н. Г.

Ярушкиной, А. П. Ротштейна, обеспечивает формализованную обработку качественной экспертной информации и является методически обоснованным выбором для построения СППР по оценке рисков внедрения ИИ. Гибридная схема «модифицированный FMEA + нечёткий вывод Мамдани + дефаззификация центром тяжести» формирует методический контур разрабатываемой системы.

6. На основании теоретического обзора уточняется научно-практическая задача исследования: разработка структуры и программной реализации СППР, интегрирующей перечисленные методические решения и обеспечивающей интегральную оценку рисков ИИ-проектов с категоризацией и обоснованной рекомендацией для лица, принимающего решение. Решение указанной задачи рассматривается во второй и третьей главах.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. О развитии искусственного интеллекта в Российской Федерации : Указ Президента Российской Федерации от 10 октября 2019 г. № 490 (с изменениями от 15 февраля 2024 г. № 124). — Доступ из СПС «КонсультантПлюс».
2. О проведении эксперимента по установлению специального регулирования в целях создания необходимых условий для разработки и внедрения технологий искусственного интеллекта в субъекте Российской Федерации — городе федерального значения Москве и внесении изменений в статьи 6 и 10 Федерального закона «О персональных данных» : Федеральный закон от 24 апреля 2020 г. № 123-ФЗ.
3. О персональных данных : Федеральный закон от 27 июля 2006 г. № 152-ФЗ.
4. Кодекс этики в сфере искусственного интеллекта : принят 26 октября 2021 г. — URL: <https://ethics.a-ai.ru> (дата обращения: 05.05.2026).
5. ГОСТ Р ИСО 31000-2019. Менеджмент риска. Принципы и руководство. — Москва : Стандартинформ, 2020. — 19 с.
6. ГОСТ Р ИСО/МЭК 31010-2021. Менеджмент риска. Методы оценки риска. — Москва : Стандартинформ, 2021. — 92 с.
7. ГОСТ Р 59276-2020. Системы искусственного интеллекта. Способы обеспечения доверия. Общие положения. — Москва : Стандартинформ, 2021. — 12 с.
8. ГОСТ Р 27.303-2021. Надёжность в технике. Анализ видов и последствий отказов (FMEA). — Москва : Стандартинформ, 2021. — 28 с.
9. ISO/IEC 23894:2023. Artificial intelligence — Guidance on risk management. — Geneva : ISO, 2023. — 35 p.
10. ISO/IEC 42001:2023. Artificial intelligence — Management system. — Geneva : ISO, 2023. — 38 p.
11. ISO/IEC 22989:2022. Artificial intelligence — Concepts and terminology. — Geneva : ISO, 2022. — 53 p.

12. ISO/IEC TR 24028:2020. Information technology — Artificial intelligence — Overview of trustworthiness in AI. — Geneva : ISO, 2020. — 50 p.
13. Artificial Intelligence Risk Management Framework (AI RMF 1.0) / National Institute of Standards and Technology. — Gaithersburg : NIST, 2023. — 48 p.
14. Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). — Official Journal of the European Union. — 2024. — L 1689.
15. Заде Л. А. Понятие лингвистической переменной и его применение к принятию приближённых решений / Л. А. Заде ; пер. с англ. — Москва : Мир, 1976. — 165 с.
16. Борисов А. Н. Принятие решений на основе нечётких моделей. Примеры использования / А. Н. Борисов, О. А. Крумберг, И. П. Фёдоров. — Рига : Зинатне, 1990. — 184 с.
17. Леоненков А. В. Нечёткое моделирование в среде MATLAB и fuzzyTECH / А. В. Леоненков. — Санкт-Петербург : БХВ-Петербург, 2005. — 736 с.
18. Ярушкина Н. Г. Основы теории нечётких и гибридных систем : учебное пособие / Н. Г. Ярушкина. — Москва : Финансы и статистика, 2004. — 320 с.
19. Ротштейн А. П. Интеллектуальные технологии идентификации : нечёткая логика, генетические алгоритмы, нейронные сети / А. П. Ротштейн. — Винница : УНИВЕРСУМ-Винница, 1999. — 320 с.
20. Билятдинов К. З. Управление рисками технологических изменений в производственных системах / К. З. Билятдинов, В. М. Кривцов. — Санкт-Петербург : ГУАП, 2022. — 224 с.
21. Гетманова Г. В. Инновационный менеджмент : учебное пособие / Г. В. Гетманова. — Санкт-Петербург : ГУАП, 2020. — 188 с.

22. Mamdani E. H. An experiment in linguistic synthesis with a fuzzy logic controller / E. H. Mamdani, S. Assilian // International Journal of Man-Machine Studies. — 1975. — Vol. 7, № 1. — P. 1–13.

23. Vaswani A. Attention Is All You Need / A. Vaswani, N. Shazeer, N. Parmar [et al.] // Advances in Neural Information Processing Systems. — 2017. — Vol. 30. — P. 5998–6008.

24. Liu H. C. Improving risk evaluation in FMEA with cloud model and hierarchical TOPSIS method / H. C. Liu, X. Q. Chen, Y. P. Hou [et al.] // IEEE Transactions on Fuzzy Systems. — 2021. — Vol. 29, № 8. — P. 2334–2348.

25. Mökander J. Auditing of AI: Legal, ethical and technical approaches / J. Mökander // Digital Society. — 2023. — Vol. 2, № 3. — Article 49.

26. Yazdi S. Failure Mode and Effects Analysis (FMEA) and Fuzzy FMEA approaches: A literature review / S. Yazdi, S. Hosseini, F. Khan // Process Safety and Environmental Protection. — 2020. — Vol. 138. — P. 188–211.

27. Stanford AI Index Report 2024 / Human-Centered AI Institute, Stanford University. — Stanford : Stanford HAI, 2024. — 393 p.

28. Cost of a Data Breach Report 2024 / IBM Security. — Armonk : IBM Corporation, 2024. — 78 p.

29. Russia AI Index 2024 : аналитический доклад / Центр технологий искусственного интеллекта НИУ ВШЭ. — Москва : НИУ ВШЭ, 2024. — 156 с.

30. Гартнер. The CIO's Guide to Generative AI Implementation: 2024 Edition / Gartner Research. — Stamford : Gartner, 2024. — 42 p.